

a) $\beta(\alpha, \beta) = \frac{\Gamma(\alpha, \beta)}{\Gamma(\alpha) \cdot \Gamma(\beta)}$

$p(\theta | x) = \frac{p(x|\theta) p(\theta)}{\int_0^1 p(x|\theta) p(\theta) d\theta} \propto p(x|\theta) p(\theta)$
(تقریب مستطال)

$X_i \sim \text{binom}(N, \theta) \rightarrow p\{x_i | N, \theta\} = \binom{N}{x_i} \theta^{x_i} (1-\theta)^{N-x_i}$

$p(\theta) = \frac{1}{\beta(\alpha, \beta)} \theta^{\alpha-1} (1-\theta)^{\beta-1}$

$\Rightarrow p(\theta | x) = \frac{1}{\beta(\alpha, \beta)} \binom{N}{x_i} \theta^{x_i + \alpha - 1} (1-\theta)^{N + \beta - x_i - 1}$

$p(\theta | x) = \binom{N}{x_i} \times \frac{1}{\beta(\alpha, \beta)} \times p^{\sum x_i - \alpha + 1} (1-p)^{nN + \beta - \sum x_i - 1}$
 $p(\theta | x) \sim \text{beta}(\sum x_i - \alpha, nN + \beta - \sum x_i)$ posterior dist

b)

تابع توزیع تایلور (prior) در فرم توزیع دینین و احتمالات اما با افزایش تعداد دفعات آزمای تکراری این تابع تغییر می کند

معمایه

c)

تابع یونیفرم (uniform) نوع خاصی از توزیع دینین است (با $\alpha = \beta = 1$) در آن

$p(\theta | x) \sim \text{beta}(\sum x_i + 1, nN - \sum x_i + 1) \rightarrow p(\theta | x) \propto \theta^{\sum x_i} (1-\theta)^{\sum N - x_i}$

d) $\rightarrow \mathcal{S}(\text{code})$

در اینجا تابع دینین یک binominal خواهد شد

a) good dice $\rightarrow p_r(n \geq 4) = \frac{4}{12} = 0.75$

bad dice $\rightarrow p_r(n \geq 4) = 0.5$

$p_r(H_1 | n \geq 4) = \frac{p_r(H_1) \cdot p_r(n \geq 4 | H_1)}{p_r(n \geq 4)}$

$\frac{0.5 \times 0.75}{0.5 \times 0.75 + 0.5 \times 0.5} = 0.6$

b) $\rightarrow \text{code}$

$p_r(H_2 | n \geq 4) = 0.4$

c) Bayesian به بار دینین و وابسته است به این صورت که ما با این بارهای دینین و فضاها را اطلاع می دهیم
هر بار احتمال های دینین را که برای این است که این update می کنیم و در واقع اگر بار دینین های ما را

دورین ابهری تارنیم چین در روش frequentist مایر الی و نکته اینست که به صورت کلی و یکجا نباید از کل آن ها استفاده کنیم
 حال آن که در bayesian به تفکیک با این روش (با روش مایر الی) کار می کنیم.

3
 اتمام

تعیین prior $p(x) \rightarrow \frac{1}{\sqrt{2\pi}\sigma_x} e^{-\frac{x^2}{2\sigma_x^2}} \rightarrow x = \mu$
 $y = \mu + w$
 $y|x = \mu \sim N(\mu, \sigma_w^2) \Rightarrow f_{y|x}(y|x) = \frac{1}{\sqrt{2\pi}\sigma_w} e^{-\frac{(y-x)^2}{2\sigma_w^2}}$

تعیین posterior $\rightarrow f_{y|x}(y|x) f_x(x) = \frac{1}{2\pi\sigma_x\sigma_w} e^{-\left[\frac{(y-x)^2}{2\sigma_w^2} + \frac{x^2}{2\sigma_x^2}\right]} \xrightarrow{\max}$
 \downarrow
 e^{-x} چون در توان
 $\rightarrow \min x$ تابع ما اگر به هم (بند) بیاوریم

$\frac{\partial f(x)}{\partial x} = 0 \Rightarrow -\frac{(y-x)}{\sigma_w^2} + \frac{x}{\sigma_x^2} = 0 \rightarrow \hat{x}_{map} = \frac{\sigma_x^2}{\sigma_x^2 + \sigma_w^2} y$

$\hat{x}_{map} = \arg \min_x \frac{(y-x)^2}{2\sigma_w^2} + \frac{x^2}{2\sigma_x^2}$

b) $\hat{x}_{map} \rightarrow 0$ $\hat{x}_{map} \propto \frac{1}{\sigma_w^2}$ $\sigma_w^2 \rightarrow \infty$ (3) ?

واقعیت اگر σ_w^2 بزرگ شود معادله ما این است که هر آنچه می بینیم x متاثر از نویز زیاد دارد چون σ_w بزرگتر است که بدون نویز به x خالص را می بینیم

توابع پیشین (prior) \rightarrow $\begin{cases} H_0: x = -1 \\ H_1: x = 1 \end{cases}$ $\rightarrow \begin{cases} P_r(H_0) = 1-p \\ P_r(H_1) = p \end{cases}$ $\rightarrow Y = -2 + w \rightarrow Y | H_0 \sim N(-2, \sigma^2)$ (4) $\rightarrow Y = 2 + w \rightarrow Y | H_1 \sim N(2, \sigma^2)$

توابع پسین (posterior) $\begin{cases} P_r(H_0 | Y=y) = f_Y(y | H_0) P_r(H_0) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(y+2)^2}{2\sigma^2}} \cdot (1-p) \\ P_r(H_1 | Y=y) = f_Y(y | H_1) P_r(H_1) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(y-2)^2}{2\sigma^2}} \cdot p \end{cases}$

نویز صفر (H_0) زمانی روی می خورد که احتمال پسین (posterior) $P_r(H_1 | Y=y)$ از احتمال پیشین $P_r(H_0)$ بزرگتر باشد.

پارامتر $\rightarrow \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(y-2)^2}{2\sigma^2}} \cdot p > \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(y+2)^2}{2\sigma^2}} \cdot (1-p) \rightarrow y > \frac{\sigma^2}{2} \ln \frac{(1-p)}{p}$
 در این صورت می توان H_1 را رد کرد و در غیر این صورت H_0 را رد نمی شود.

(5) الگوریتم Metropolis-Hastings برای به دست آوردن دنباله ای از نمونه های تصادفی از توزیع احتمال می است که نمونه برداری به طور مستقیم آن معادله را می باشد این روش یکی از روش های خانواده مونت کارلو است و در نمونه برداری از توزیع های پسین (posterior) کاربرد دارد.

روش الگوریتم: (I) وجود توزیع ثابت $\pi(x)$ به شکل detailed balance (نیست)؟ هر $x \rightarrow x'$ قابل برگشت داخل بودن در state x و باز x بایر با بودن در x' .

تبدیل x به x' این است: $\pi(x) p(x' | x) = \pi(x') p(x | x')$

(2) تابعی از توزیع $\pi(x)$

طرح $\rightarrow p(x) \cdot p(x' | x) = p(x') \cdot p(x | x') \rightarrow \frac{p(x' | x)}{p(x | x')} = \frac{p(x')}{p(x)}$ detailed balance

هدف تقسیم هدف را به دو مرحله acceptance-reject: proposal است. $p(x', x) = g(x' | x) A(x', x)$
 Acceptance: قبول کردن
 Proposal: پیشنهاد
 احتمال: احتمال

a)

(5) b1

$$\textcircled{I} \rightarrow \frac{\Lambda(n', n)}{\Lambda(n, n)} = \frac{p(n') g(n|n')}{p(n) g(n'|n)}$$

acceptance/rejection

↓

$$\Lambda(n', n) = \min\left(1, \frac{p(n')}{p(n)} \cdot \frac{g(n|n')}{g(n'|n)}\right)$$

Ⓘ مقبولیت

state $\theta = \theta_0 (= \dots)$ $t = 0$

Ⓙ Iteration (for —)

state n'

$$\rightarrow \text{Acceptance/rejection} \rightarrow \Lambda(n', n_t) = \min\left(1, \frac{p(n')}{p(n_t)} \cdot \frac{g(n_t|n')}{g(n'|n_t)}\right)$$

Ⓜ Accept/reject

- $u \in [0, 1]$
↓
random- $u \leq \Lambda(n', n_t) \rightarrow$ accept n' as new state $n_{t+1} = n'$ - $u > \Lambda(n', n_t) \rightarrow$ reject n' as new state $n_{t+1} = n_t$ Ⓝ repeat the iteration $t = t+1$ (until the states are out.)

Ⓔ در اینجا نکته‌ای که مهم است این است که مقایسه (مقادیر) برای در جایی که آن‌ها بسیار مهم است و دانستن آن می‌تواند در نتیجه‌گیری بسیار مهم است. ما در اینجا به مقایسه حالت‌ها و در خصوص $sensitivity$ و $specificity$ به بحث می‌پردازیم. به نظر می‌رسد که این مقایسه‌ها می‌تواند به ما کمک کند تا بفهمیم که آیا این وجود درستی است (غلطی).

این بارادرس $veridical$ پارادوکس (که به معنی واقعی است) می‌باشد. این پارادوکس به نظر می‌رسد که می‌تواند به ما کمک کند تا بفهمیم که آیا این وجود درستی است (غلطی).

b) odds: number of { sick: healthy } $\xrightarrow{p(s)}$ positive odds
update: { sick: healthy } $\times \frac{p(s|s)}{p(s|h)}$ \rightarrow healthy $\rightarrow p(h)$ \downarrow $p(p)$ \rightarrow odds
positive odds \rightarrow odds

داریم { prior odds: 1:99
bayes' factor: $\frac{Pr\{P|s\}}{Pr\{P|h\}} = \frac{90\%}{9\%} = 10$
posterior odds: 10:99 $\rightarrow \frac{10}{109} \approx 0.092$ }

(4)

c)
$$\text{Bayes' factor} = \frac{\text{sensitivity}}{\text{FPR}} = \frac{P\{P|S\}}{P\{P|h\}} \rightarrow \text{کم برای prior} \quad \text{posterior} \approx \text{prior (Bayes' factor)}$$

← برای prior قابلیت از odd استفاده نمی چندان نیست.

داریم

$$\left\{ \begin{array}{l} \text{راه معرزی} \rightarrow P(S|P) = \frac{P(P|S) \cdot P(S)}{P(P|S) + P(P|h)} = \frac{\text{Prior} \cdot (\text{sensitivity})}{\text{Prior} \cdot (\text{sensitivity}) + (1 - \text{prior}) \cdot (\text{FPR})} \\ \text{odds} \rightarrow O(S|P) = O(S) \cdot \frac{P\{P|S\}}{P\{P|h\}} = \text{prior} \cdot \frac{\text{sensitivity}}{\text{FPR}} \end{array} \right.$$

در مورد odds چون نتایج (FPR, sensitivity) و همچنین احتمال پیشین (prior) از هم جدا هستند اولاً باید کفایت اطلاعاتی خود را
ثانیاً چون از هم جدا هستند می توان نسبت prior های مختلف را نسبت به هم کرد و آن را در روش معمول چون این ترم ها با هم مخلوط شده
اند و سر به پا می شوند با استفاده از این داریم و نسبت prior ها را نسبت به هم قرار می دهیم و آن را به بعد هم چسب می دهیم برای انجام
iteration های زیاد به سبب این است (نتیجه گیری) و به این کار می توان در نوشتن برنامه ها کمک کرد و به سبب این که می توان راه معمولی می کند.

d)

$$\left\{ \begin{array}{l} \text{prior odds } O(\text{sick}) = 8:92 \\ \text{sensitivity} = 0.8 \\ \text{odds } 1:9 \rightarrow \text{FPR} = 0.1 \\ (P|h) \end{array} \right. \Rightarrow \text{Bayes' factor} = \frac{\text{sensitivity}}{\text{FPR}} = 8$$

$$O(S|P) = O(S) \times \text{Bayes' factor} = 64:92$$

$$O = \frac{64}{156} \approx 0.41 \quad \downarrow \text{احتمال}$$